

MAT02018 - Estatística Descritiva

Medidas de variabilidade

Rodrigo Citton P. dos Reis
citton.padilha@ufrgs.br

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
INSTITUTO DE MATEMÁTICA E ESTATÍSTICA
DEPARTAMENTO DE ESTATÍSTICA

Porto Alegre, 2021



Introdução

Introdução

- ▶ As medidas de tendência central são insuficientes para representar adequadamente conjuntos de dados, pois nada revelam sobre sua **variabilidade**.
- ▶ Tome como exemplo as notas de 5 avaliações realizadas por 2 alunos.
 - ▶ **Aluno A:** 6, 6, 6, 6, 6.
 - ▶ **Total de pontos:** 30; **Média:** 6.
 - ▶ **Aluno B:** 7, 5, 6, 4, 8.
 - ▶ **Total de pontos:** 30; **Média:** 6.

Introdução

- ▶ Para mostrar a diversidade de desempenho de ambos, necessita-se de um valor que meça a **dispersão** ou a **variabilidade** dos valores nos dois casos.
- ▶ Nestas notas de aula vamos apresentar algumas das medidas mais utilizadas para descrever a variabilidade de um conjunto de dados.

Amplitude de variação

Amplitude de variação

- ▶ A medida mais simples de dispersão é a **amplitude de variação** (a), que é a diferença entre os valores extremos do conjunto de dados.
- ▶ $a = \text{Max}(x) - \text{Min}(x)$, em que $\text{Min}(x)$ e $\text{Max}(x)$ representam os valores de **mínimo** e **máximo** de um conjunto de dados, respectivamente.

Amplitude de variação

- **Exemplo:** suponha que observamos a **largura da pétala** (em centímetros) de 10 flores

1.3	0.2	0.2	1.9	2.0
1.3	1.8	0.4	0.6	0.1

Amplitude de variação

- ▶ Note que,
 - ▶ $Min(x) = 0.1$;
 - ▶ $Max(x) = 2$;
- ▶ Logo, a amplitude é $a = 2 - 0.1 = 1.9$

Amplitude de variação

Comentário

- ▶ Os valores de mínimo e máximo de um conjunto de dados podem ser utilizados para a verificação de inconsistências nos dados com respeito a variável de interesse.
 - ▶ **Exemplos:**
 - ▶ $Max(idade) = 170$ (anos).
 - ▶ $Min(temperatura) = -20^{\circ}$ (na série histórica de temperaturas na cidade de Porto Alegre).

Amplitude de variação




Duas limitações

1. A amplitude de variação só utiliza os valores extremos do conjunto de dados.
2. Quando avaliada em amostras, frequentemente *subestima* a amplitude populacional.

Variância

Variância

- ▶ As principais medidas de dispersão envolvem os **desvios em relação a média**, $x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_n - \bar{x}$.
- ▶ Ou seja, os desvios da média são obtidos pela subtração de \bar{x} de cada uma das n observações da amostra, conforme mostra a figura a seguir.



Variância

- ▶ Um desvio será positivo se a observação for maior que a média (à direita da média no eixo das medidas) e negativo se a observação for menor que a média.
- ▶ Se todos os desvios forem pequenos em magnitude, todos os x_i estarão próximos à média e haverá pouca dispersão.
- ▶ Por outro lado, se alguns desvios forem grandes, alguns x_i estarão distantes de \bar{x} , indicando maior dispersão.

Variância

- ▶ Uma forma simples de combinar os desvios em uma única quantidade é calcular a sua média.
 - ▶ No entanto, temos que a soma dos desvios é igual a zero, conforme mostramos a seguir

$$\begin{aligned}\sum_{i=1}^n (x_i - \bar{x}) &= \sum_{i=1}^n x_i - \sum_{i=1}^n \bar{x} \\ &= \sum_{i=1}^n x_i - n\bar{x} \\ &= \sum_{i=1}^n x_i - n \left(\frac{1}{n} \sum_{i=1}^n x_i \right) = 0.\end{aligned}$$

Variância

- ▶ Como podemos evitar desvios negativos e positivos ao neutralizar um ao outro quando eles são combinados?
- ▶ Uma possibilidade é trabalhar com os **valores absolutos** e calcular o **desvio médio absoluto** $\frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$.
 - ▶ Porém, a operação em valor absoluto conduz a dificuldades teóricas, e uma alternativa é considerar o **quadrado dos desvios** $(x_i - \bar{x})^2$ (também conhecidos como desvios quadráticos).
 - ▶ E dessa forma temos a definição da **variância**.

Variância

- ▶ A **variância** é a média dos desvios quadráticos com respeito a média.
- ▶ É representada pelo símbolo σ^2 **na população** e por s^2 **na amostra**.

Note que, por definição (a média de dos quadrados dos desvios), **a variância é uma medida não negativa**.

Variância

- ▶ Na população calculamos a variância da seguinte forma:

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n}.$$

- ▶ Na amostra, calculamos a variância da seguinte forma:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}.$$

Variância

- **Exemplo:** considere mais uma vez valores observados da largura da pétala em centímetros (de 4 flores)

1.3	1.3	0.2	1.8
-----	-----	-----	-----

Variância

- Note que $\bar{x} = 1.15$, e assim a variância da largura da pétala é

$$\begin{aligned}s^2 &= \frac{(1.3 - 1.15)^2 + (1.3 - 1.15)^2 + (0.2 - 1.15)^2 + (1.8 - 1.15)^2}{4 - 1} \\&= \frac{(0.15)^2 + (0.15)^2 + (-0.95)^2 + (0.65)^2}{3} \\&= \frac{1.37}{3} \approx 0.46 \text{ cm}^2.\end{aligned}$$

Variância

Observações

1. Note que unidade de medida da variável em questão fica expressa ao quadrado na variância.
2. A variância é uma medida de variabilidade em torno da média.
 - ▶ Se todas as observações são iguais, não há variabilidade nos dados e $s^2 = 0$.
 - ▶ Se os dados são muito dispersos com respeito a média, então a variabilidade é grande e s^2 assume um valor alto.
 - ▶ Se os dados são pouco dispersos em torno da média, então a variabilidade é pequena e s^2 assume um valor baixo.

Variância

- Uma forma alternativa de calcularmos a variância é dada pela expressão¹.

$$s^2 = \frac{\sum_{i=1}^n x_i^2 - \frac{(\sum_{i=1}^n x_i)^2}{n}}{n - 1}.$$

¹**Sua vez:** demonstre o resultado da expressão alternativa. Dica: desenvolva o quadrado da soma, reescreva o somatório e perceba que $\sum_{i=1}^n x_i = n\bar{x}$ e

$$n\bar{x}^2 = (\sum_{i=1}^n x_i)^2 / n$$

Variância

- Esta expressão nos auxilia no cálculo de s^2 quando estamos usando uma planilha eletrônica que comporta fórmulas, ou um software como R que realiza operações vetoriais.

-	x_i	$(x_i - \bar{x})$	$(x_i - \bar{x})^2$	x_i^2
	7	1	1	49
	5	-1	1	25
	6	0	0	36
	4	-2	4	16
	8	2	4	64
Soma	30	0	10	190

Variância

- ▶ Assim, temos

- ▶ $\bar{x} = 30/5 = 6;$

- ▶ $s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} = \frac{10}{4} = 2,5.$

- ▶ Ou, pela fórmula alternativa,

- ▶ $s^2 = \frac{\sum_{i=1}^n x_i^2 - \frac{(\sum_{i=1}^n x_i)^2}{n}}{n-1} = \frac{190 - \frac{30^2}{5}}{4} = 2,5.$

Desvio padrão

Desvio padrão

- ▶ Uma dificuldade com a variância, como medida descritiva da dispersão, é o fato de não poder ser apresentada com a **mesma unidade** com que a variável foi medida.
- ▶ A solução é extrair a raiz quadrada positiva da variância, já que, com isso, se volta à unidade original da variável.
- ▶ Essa nova medida de variabilidade é denominada **desvio padrão**.

Desvio padrão

- ▶ O desvio padrão populacional é definido como

$$\sigma = \sqrt{\sigma^2}.$$

- ▶ E o desvio padrão amostral² é definido como

$$s = \sqrt{s^2}.$$

- ▶ **Sua vez:** calcule o desvio padrão para os exemplos anteriores.

²Também é denotado por *DP* (de desvio padrão) ou *SD* (do inglês *standard deviation*).

Coeficiente de variação

Coeficiente de variação

- ▶ Quando se analisa a mesma variável em duas amostras, pode-se comparar os desvios padrão observados e verificar onde a variação (variabilidade) é maior.

Exemplo (espessura das sementes)

- ▶ Amostra 1 apresenta desvio padrão igual 1,29mm;
- ▶ Amostra 2 apresenta desvio padrão igual 0,51mm;
 - ▶ logo a Amostra 2 apresenta uma menor variabilidade da espessura das sementes em relação a Amostra 1.

Coeficiente de variação

- ▶ No entanto, o mesmo não pode ser feito em se tratando de variáveis diferentes (mensuradas em diferentes unidades).
- ▶ Se as sementes do exemplo anterior foram também pesadas, e o desvio padrão foi 0,009g para a Amostra 1, **não se pode afirmar** que o peso das sementes é uma característica com **menor dispersão** (“menos variável”) do que a sua espessura.

Coeficiente de variação

- ▶ Para comparar variabilidades, neste caso, deve-se usar o **coeficiente de variação (CV)**, que é uma medida de dispersão **independente da unidade de mensuração** da variável.
- ▶ O coeficiente de variação é definido como a razão entre o desvio padrão e a média da variável

$$CV = \frac{s}{\bar{x}} \quad \text{ou} \quad CV = 100\% \times \frac{s}{\bar{x}}.$$

Coeficiente de variação

Exemplo (continuação)

- ▶ Suponha que a média da espessura das sementes tenha sido observada em 5 e a média do peso das sementes tenha sido 0,05.
- ▶ Para a espessura, temos que $CV_{esp} = \frac{1,29}{5} = 0,258$, e para o peso, temos que $CV_{peso} = \frac{0,009}{0,05} = 0,18$.
- ▶ Concluimos que o peso possui menor variabilidade que a espessura neste conjunto de dados.

Para casa

1. Resolver os exercícios 1 a 4, 6 a 8 do Capítulo 9.7 do livro **Fundamentos de Estatística**³ (disponível no Sabi+).
2. Para o seu levantamento estatístico, calcule a amplitude de variação, a variância, o desvio padrão e coeficiente de variação, de acordo com a classificação das variáveis. Compartilhe no Fórum Geral do Moodle.

³Vieira, S. **Fundamentos de Estatística**, Atlas, 2019, p. 135-136.

Próxima aula

- ▶ Medidas de variabilidade (continuação):
 - ▶ Amplitude entre quartis;
 - ▶ Separatrizes: quantis, quartis, decis, percentis;
 - ▶ Gráfico de *boxplot*.
 - ▶ ComplementaR.

Por hoje é só!

Bons estudos!

