

# MAT02018 - Estatística Descritiva

## Medidas de variabilidade

Rodrigo Citton P. dos Reis  
citton.padilha@ufrgs.br

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL  
INSTITUTO DE MATEMÁTICA E ESTATÍSTICA  
DEPARTAMENTO DE ESTATÍSTICA

Porto Alegre, 2022

# Introdução

# Introdução

- ▶ As medidas de tendência central são insuficientes para representar adequadamente conjuntos de dados, pois nada revelam sobre sua **variabilidade**.
- ▶ Tome como exemplo as notas de 5 avaliações realizadas por 2 **alun@s**.
  - ▶ **Alun@ A:** 6, 6, 6, 6, 6.
    - ▶ **Total de pontos:** 30; **Média:** 6.
  - ▶ **Alun@ B:** 7, 5, 6, 4, 8.
    - ▶ **Total de pontos:** 30; **Média:** 6.

# Introdução

- ▶ Para mostrar a diversidade de desempenho de ambos, necessita-se de um valor que meça a **dispersão** ou a **variabilidade** dos valores nos dois casos.
- ▶ Nestas notas de aula vamos apresentar algumas das medidas mais utilizadas para descrever a variabilidade de um conjunto de dados.

## Amplitude de variação

# Amplitude de variação

- ▶ A medida mais simples de dispersão é a **amplitude de variação ( $a$ )**, que é a diferença entre os valores extremos do conjunto de dados.

$$a = \text{Max}(x) - \text{Min}(x),$$

em que  $\text{Min}(x)$  e  $\text{Max}(x)$  representam os valores de **mínimo** e **máximo** de um conjunto de dados, respectivamente.

# Amplitude de variação

- **Exemplo:** suponha que observamos a **largura da pétala** (em centímetros) de 10 flores

1.3	0.2	0.2	1.9	2.0
1.3	1.8	0.4	0.6	0.1

# Amplitude de variação

- ▶ Note que,
  - ▶  $\text{Min}(x) = 0.1$ ;
  - ▶  $\text{Max}(x) = 2$ ;
- ▶ Logo, a amplitude é  $a = 2 - 0.1 = 1.9$



# Amplitude de variação

## Comentário

- ▶ Os valores de mínimo e máximo de um conjunto de dados podem ser utilizados para a **verificação de inconsistências nos dados** com respeito a variável de interesse.
  - ▶ Exemplos:
    - ▶  $Max(idade) = 170$  (anos).
    - ▶  $Min(temperatura) = -20^{\circ}$  (na série histórica de temperaturas na cidade de Porto Alegre).

# Amplitude de variação




## Duas limitações

1. A amplitude de variação só utiliza os valores extremos do conjunto de dados.
2. Quando avaliada em amostras, frequentemente *subestima* a amplitude populacional.

# Variância

# Variância

- ▶ As principais medidas de dispersão envolvem os **desvios em relação a média**:  $x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_n - \bar{x}$ .
- ▶ Ou seja, os desvios da média são obtidos pela subtração de  $\bar{x}$  de cada uma das  $n$  observações da amostra, conforme mostra a figura a seguir.



# Variância

- ▶ Um desvio será positivo se a observação for maior que a média (à direita da média no eixo das medidas) e negativo se a observação for menor que a média.
- ▶ Se todos os desvios forem pequenos em magnitude, todos os  $x_i$  estarão próximos à média e haverá pouca dispersão.
- ▶ Por outro lado, se alguns desvios forem grandes, alguns  $x_i$  estarão distantes de  $\bar{x}$ , indicando maior dispersão.

# Variância

- ▶ Uma forma simples de combinar os desvios em uma única quantidade é calcular a sua média.
  - ▶ No entanto, temos que a soma dos desvios é igual a zero, conforme mostramos a seguir

$$\begin{aligned}\sum_{i=1}^n (x_i - \bar{x}) &= \sum_{i=1}^n x_i - \sum_{i=1}^n \bar{x} \\ &= \sum_{i=1}^n x_i - n\bar{x} \\ &= \sum_{i=1}^n x_i - n \left( \frac{1}{n} \sum_{i=1}^n x_i \right) = 0.\end{aligned}$$

# Variância

- ▶ Como podemos evitar desvios negativos e positivos ao neutralizar um ao outro quando eles são combinados?
- ▶ Uma possibilidade é trabalhar com os **valores absolutos** e calcular o desvio médio absoluto  $\frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$ .
  - ▶ Porém, a operação em valor absoluto conduz a dificuldades teóricas, e uma alternativa é considerar o quadrado dos desvios  $(x_i - \bar{x})^2$  (também conhecidos como desvios quadráticos).
  - ▶ E dessa forma temos a definição da **variância**.

# Variância

- ▶ A **variância** é a média dos desvios quadráticos com respeito a média.
- ▶ É representada pelo símbolo  $\sigma^2$  **na população** e por  $s^2$  **na amostra**.

## Observação

Note que, por definição (a média de dos quadrados dos desvios), a **variância é uma medida não negativa**.



# Variância

- ▶ Na população calculamos a variância da seguinte forma:

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N}.$$

- ▶ Na amostra, calculamos a variância da seguinte forma:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}.$$

# Variância

- **Exemplo:** considere mais uma vez valores observados da largura da pétala em centímetros (de 4 flores)

1.3	1.3	0.2	1.8
-----	-----	-----	-----

# Variância

► Note que  $\bar{x} = 1.15$ , e assim a variância da largura da pétala é

$$\begin{aligned}s^2 &= \frac{(1.3 - 1.15)^2 + (1.3 - 1.15)^2 + (0.2 - 1.15)^2 + (1.8 - 1.15)^2}{4 - 1} \\&= \frac{(0.15)^2 + (0.15)^2 + (-0.95)^2 + (0.65)^2}{3} \\&= \frac{1.37}{3} \approx 0.46 \text{ cm}^2.\end{aligned}$$

# Variância

## Observações

1. Note que unidade de medida da variável em questão fica expressa ao quadrado na variância.
2. A variância é uma medida de variabilidade em torno da média.
  - ▶ Se todas as observações são iguais, não há variabilidade nos dados e  $s^2 = 0$ .
  - ▶ Se os dados são muito dispersos com respeito a média, então a variabilidade é grande e  $s^2$  assume um valor alto.
  - ▶ Se os dados são pouco dispersos em torno da média, então a variabilidade é pequena e  $s^2$  assume um valor baixo.

# Variância

- Uma forma alternativa de calcularmos a variância é dada pela expressão<sup>1</sup>.

$$s^2 = \frac{\sum_{i=1}^n x_i^2 - \frac{(\sum_{i=1}^n x_i)^2}{n}}{n - 1}.$$

---

<sup>1</sup>**Sua vez:** demonstre o resultado da expressão alternativa. Dica: desenvolva o quadrado da soma, reescreva o somatório e perceba que  $\sum_{i=1}^n x_i = n\bar{x}$  e

$$n\bar{x}^2 = (\sum_{i=1}^n x_i)^2 / n$$

# Variância

- Esta expressão nos auxilia no cálculo de  $s^2$  quando estamos usando uma planilha eletrônica que comporta fórmulas, ou um software como R que realiza operações vetoriais.

-	$x_i$	$(x_i - \bar{x})$	$(x_i - \bar{x})^2$	$x_i^2$
	7	1	1	49
	5	-1	1	25
	6	0	0	36
	4	-2	4	16
	8	2	4	64
Soma	30	0	10	190

# Variância

- ▶ Assim, temos

- ▶  $\bar{x} = 30/5 = 6;$

- ▶  $s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} = \frac{10}{4} = 2,5.$

- ▶ Ou, pela fórmula alternativa,

- ▶  $s^2 = \frac{\sum_{i=1}^n x_i^2 - \frac{(\sum_{i=1}^n x_i)^2}{n}}{n-1} = \frac{190 - \frac{30^2}{5}}{4} = 2,5.$

# Desvio padrão



# Desvio padrão

- ▶ Uma dificuldade com a variância, como medida descritiva da dispersão, é o fato de não poder ser apresentada com a **mesma unidade** com que a variável foi medida.
- ▶ A solução é extrair a raiz quadrada positiva da variância, já que, com isso, se volta à unidade original da variável.
- ▶ Essa nova medida de variabilidade é denominada **desvio padrão**.

# Desvio padrão

- ▶ O desvio padrão populacional é definido como

$$\sigma = \sqrt{\sigma^2}.$$

- ▶ E o desvio padrão amostral<sup>2</sup> é definido como

$$s = \sqrt{s^2}.$$

- ▶ **Sua vez:** calcule o desvio padrão para os exemplos anteriores.

---

<sup>2</sup>Também é denotado por **DP** (de desvio padrão) ou **SD** (do inglês *standard deviation*).

## Coeficiente de variação

# Coeficiente de variação

- ▶ Quando se analisa a mesma variável em duas amostras, pode-se comparar os desvios padrão observados e verificar onde a variação (variabilidade) é maior.

## Exemplo (espessura das sementes)

- ▶ Amostra 1 apresenta desvio padrão igual 1,29mm;
- ▶ Amostra 2 apresenta desvio padrão igual 0,51mm;
  - ▶ Logo a Amostra 2 apresenta uma menor variabilidade da espessura das sementes em relação a Amostra 1.

# Coeficiente de variação

- ▶ No entanto, o mesmo não pode ser feito em se tratando de variáveis que foram mensuradas em diferentes unidades de medida.
- ▶ Se as sementes do exemplo anterior foram também pesadas, e o desvio padrão foi 0,009g para a Amostra 1, **não se pode afirmar** que o peso das sementes é uma característica com **menor dispersão** (“menos variável”) do que a sua espessura.

# Coeficiente de variação

- ▶ Para comparar variabilidades, neste caso, deve-se usar o **coeficiente de variação (CV)**, que é uma medida de dispersão **independente da unidade de mensuração** da variável.
- ▶ O coeficiente de variação é definido como a razão entre o desvio padrão e a média da variável

$$CV = \frac{s}{\bar{x}} \quad \text{ou} \quad CV = 100\% \times \frac{s}{\bar{x}}.$$

# Coeficiente de variação

## Exemplo (continuação)

- ▶ Suponha que a média da espessura das sementes tenha sido observada em 5 e a média do peso das sementes tenha sido 0,05.
- ▶ Para a espessura, temos que  $CV_{esp} = \frac{1,29}{5} = 0,258$ , e para o peso, temos que  $CV_{peso} = \frac{0,009}{0,05} = 0,18$ .
- ▶ Concluimos que o peso possui menor variabilidade que a espessura neste conjunto de dados.

## Para casa

1. Resolver os exercícios 1 a 4, 6 a 8 do Capítulo 9.7 do livro **Fundamentos de Estatística**<sup>3</sup> (disponível no Sabi+).
2. Para o seu levantamento estatístico, calcule a amplitude de variação, a variância, o desvio padrão e coeficiente de variação, de acordo com a classificação das variáveis. Compartilhe no Fórum Geral do Moodle.

---

<sup>3</sup>Vieira, S. **Fundamentos de Estatística**, Atlas, 2019, p. 135-136.



# Próxima aula

- ▶ Medidas de variabilidade (continuação):
  - ▶ Amplitude entre quartis;
    - ▶ Separatrizes: quantis, quartis, decis, percentis;
  - ▶ Gráfico de *boxplot*.
  - ▶ ComplementaR.

# Por hoje é só!

Bons estudos!

